



Université Côte d'Azur

Faculté des Sciences de Valrose

Master 1 Ingénierie Mathématique

Analyse de données

Rapport Projet Analyse de données :

Gestion de la Relation Clients : Segmentation de Clientèle

Réalisé par :

SA Alexandre

AZIZ GBADAMASSI Alain

Supervisé par :

Nicolas Pasquier

Année universitaire : 2025-2026

PLAN

Introduction

1. Ensemble de données (Structure, dimension ...)
2. Extraction des itemsets fréquents
 - A. Visualisation des itemsets fréquents sous forme de graphe
 - B. Visualisation des itemsets fréquents sous forme de graphe interactif
3. Règles d'association
 - A. Visualisation des règles d'association sous forme de matrice
 - B. Visualisation des règles d'association sous forme de boulier
 - C. Visualisation des règles d'association sous forme de coordonnées parallèles
 - D. Visualisation des règles d'association sous forme de graphe interactif
 - E.
4. Règles d'association indiquant les achats les plus fréquents
 - A. Règles d'association par genre
 - B. Règles d'association par catégories d'âge
 - C. Règles d'association par catégorie de revenus des clients
5. Itemsets fréquents indiquant les 4 articles le plus fréquemment achetés dans les 10 % de transactions dont le plus montant est le plus élevé
6. Clusters regroupant les clients ayant des caractéristiques et des comportements d'achats similaires
7. Caractérisation des clusters extraits (Profilage Socio-Démographique)

Conclusion

INTRODUCTION

Dans le cadre de notre projet d'analyse de données orienté vers la **Gestion de la Relation Client**, cette étude a pour objectif d'explorer et de modéliser les comportements d'achat. À partir du jeu de données *Data Projet.csv*, qui regroupe à la fois des transactions commerciales et des informations socio-démographiques, nous avons mené une double analyse **l'analyse des paniers** pour identifier les groupes d'articles fréquemment achetés simultanément (Règles d'association) et puis **la segmentation de la clientèle** : pour constituer et caractériser des profils types de consommateurs (Clustering). Ce rapport détaille les traitements effectués, les configurations algorithmiques retenues et l'interprétation stratégique des résultats obtenus.

1. Ensemble de données (Structure, dimension...)

L'ensemble de données Data Projet.csv utilisé pour cette étude contient les informations socio-démographiques et listes d'achats de produits de clients.


Dans le code nous avons nommé notre matrice de données « basket » afin de pouvoir manipuler les données

En appliquant la fonction summary() de R à basket on se rend compte qu'il y a 30 instances qui contiennent pas de genre et que la valeur maximale pour la variable Age a pour valeur 991.0 ce qui est une valeur aberrante. On fera donc attention à ces valeurs

2. Extraction des itemsets fréquents

Avant l'extraction des itemsets fréquents représentant les articles les plus fréquemment achetés simultanément, intéressons-nous à la fréquence des articles dans la matrice de données contenant uniquement les articles que nous avons nommé « basket2 ».

Nous avons transformé basket2 en une matrice de transaction « basketT » afin de pouvoir afficher les itemsets fréquents grâce à la fonction itemFrequencyPlot()




Fréquence des articles

D'après le résultat obtenu avec le graphe on peut en déduire que la « Salade » apparaît approximativement dans 35 % des transactions suivi des « céréales », « yaourt » et « sauce_tomate » qui apparaissent à peu près dans 29 % transactions. Le « café » est celle qui a la plus petite fréquence d'apparition

A. Visualisation des itemsets fréquents sous forme de graphe

Avant la visualisation des itemsets fréquents, nous les avons extraits avec la fonction **apriori ()**. Nous avons 52 itemsets fréquents en prenant un support minimal de 10% avec l'article « Salade » qui représente l'itemset avec le plus grand support (35.6 %). Nous obtenons le graphe suivant en utilisant la fonction plot () avec la méthode « graph ».



Les Étiquettes (Items) : Les textes (ex : Pâtes=1, Sauce_tomate=1, Viande_bio=1, Soda=1) représentent les articles présents dans les transactions analysées. La notation =1 indique la présence de l'article dans le panier.

Les Nœuds (Cercles rouges) : Ils représentent les règles d'association ou les combinaisons d'articles.

Les Flèches : Elles matérialisent les liens d'implication entre les produits au sein des règles.


Interprétation :

Ce graphique permet d'identifier visuellement des clusters de consommation. Par exemple, on observe des regroupements logiques comme le lien entre Pâtes, Soda, et Sauce_tomate, ou des tendances autour des produits bio. Les articles isolés (comme

Café) suggèrent qu'ils sont moins fréquemment combinés avec le reste du panier principal dans les règles à fort support.

B. Visualisation des itemsets fréquents sous forme de graphe interactif

Nous avons obtenu le graphe suivant en utilisant la fonction `plot()` avec comme paramètre : `method = "graph"` et `engine = "interactif"`.



Ce graphique est une **visualisation de réseau** sur des habitudes de consommation alimentaire.

- **Les Nœuds Verts (Les Produits) :** Ils représentent des variables ou des produits alimentaires spécifiques. L'annotation =1 (ex : Lait=1, Salade=1) indique la **présence** de ce produit.
- **Les Nœuds Roses (Les Observations) :** Ces petits cercles sans étiquette représentent les **paniers d'achats**
- **Les Liens (Traits gris) :** Ils connectent les produits aux paniers. Si un nœud rose est relié à "Lait" et à "Céréales", cela signifie que ce panier contenait à la fois du lait et des céréales.


Interprétation :

L'analyse du graphe de co-occurrences révèle une segmentation marquée de la clientèle en quatre communautés de consommation distinctes. On identifie tout d'abord un **pôle "Bio" exclusif**, où les achats (viande, poisson, fruits et légumes bio) sont dictés par une forte cohérence de label, sans mélange avec les produits standards. Deux autres groupes se définissent par la typologie des repas : un profil **"Familial"**, centré sur le petit-déjeuner et les repas d'enfants (Lait, Céréales, Jambon, Purée), et un profil **"Repas Rapide"** (Pâtes, Sauce tomate, Soda), caractéristique d'une consommation simple et économique, potentiellement étudiante. Le groupe **"Alimentation Équilibrée"** regroupe les produits frais standards (Salade, Poulet, Yaourt). Enfin, le **Café** apparaît comme un élément isolé, suggérant un achat transversal ou d'appoint qui ne s'ancre dans aucun panier type spécifique.

3. Règles d'association

Pour afficher les règles d'association, nous avons utilisés aussi la fonction `apriori()` sur la matrice de données basketT avec 10 % comme support minimal et confiance 50 % et avons obtenu 77 règles d'association que nous avons visualisé de différentes manières.

A. Visualisation des règles d'association sous forme de matrice




Analyse :

L'axe des abscisses représentent les itemsets en antécédents et l'axe des ordonnées les itemsets en conséquence. Les carrés au niveau de l'intersection antécédent, conséquence indique la règle existe. Plus la couleur de ceux-ci est rouge foncé plus le lift est élevé indiquant une association forte tandis que la couleur rouge clair indique une association faible. Par exemple ici la première colonne

représente la règle d'association " {Céréales=1, Jambon=1, Purée=1} =>{Lait=1} " et la couleur rouge présente au niveau de l'intersection indique une association forte (lift élevé).

Aussi les règles d'association {Haricot} => {Salade} et {Poulet} => {Salade} sont des règles d'association qui existent bien mais qui ont un lift faible au vu de leur couleur.

B. Visualisation des règles d'association sous forme de boulier



Analyse

L'étude a été réalisée sur le jeu de données transactionnel basketT à l'aide de l'algorithme **Apriori**. En fixant un **support minimum de 10%** et une **confiance minimum de 50%**, nous avons extrait un total de **77 règles d'association** pertinentes.

L'analyse visuelle (nuage de points) met en évidence deux tendances principales :


- **La fiabilité** : Un cluster de règles situé en haut à gauche présente une confiance très élevée (> 80%) combinée à un lift fort (couleur rouge). Cela indique des liens de causalité quasi-systématiques entre certains produits, même si ces achats sont moins fréquents au global.
- **La popularité** : Un second groupe en bas à droite montre des produits à fort support (achetés très souvent) mais avec une confiance plus modérée, typique des produits de première nécessité.

Interprétation

L'examen des règles révèle que les clients n'achètent pas au hasard, mais selon **quatre profils de consommation** bien distincts :

- **Le Panier "Santé/Frais"** : C'est le lien le plus fort de l'analyse. L'achat combiné de *Poisson*, *Pommes* et *Salade* prédit l'achat de *Yaourt* avec une fiabilité de 85%.
- **Le Panier "Famille"** : Les produits *Céréales*, *Jambon*, *Purée* et *Lait* fonctionnent en synergie. La présence des trois premiers articles triple la probabilité d'achat de lait ($Lift > 3$).
- **Le Panier "Repas Express"** : Une triangulation claire existe entre *Pâtes*, *Sauce tomate* et *Soda*, suggérant une cible plus jeune ou pressée.
- **L'Écosystème "Bio"** : Les produits bio (*Viande*, *Légumes*, *Fruits*) interagissent fortement entre eux mais très peu avec les autres produits, isolant une clientèle spécifique "100% Bio".

C. Visualisation des règles d'association sous forme de coordonnées parallèles



Analyse

Ce graphique permet de visualiser la structure interne des règles d'association sous forme de flux.


- **Fonctionnement des Axes :**
 - L'axe des **Positions (3, 2, 1)** représente les **Antécédents** (la partie "SI" de la règle ou *LHS*). La position indique le nombre d'articles dans le panier de départ (ex : une ligne partant de la position 3 signifie une règle basée sur 3 produits initiaux).
 - L'axe **rhs** (Right Hand Side) représente le **Conséquent** (la partie "ALORS" de la règle), c'est-à-dire le produit prédit.
- **Les Flux (Lignes rouges)** : Chaque ligne représente une règle. L'épaisseur et la couleur rouge indiquent la force de la règle (souvent le *Lift* ou la *Confiance*).

- **Observation Structurale** : Le graphique ne présente aucun croisement majeur entre les groupes de produits situés en haut, au milieu et en bas de l'axe vertical. Les lignes restent parallèles et groupées par zones.

Interprétation

Des silos de consommation étanches Le graphique met en évidence une segmentation stricte de la clientèle en quatre univers qui ne communiquent pas entre eux. On observe des circuits fermés : les acheteurs de produits Bio restent exclusifs à cette gamme, sans interaction avec les produits standards. De même, l'univers "Épicerie/Famille" (Pâtes, Soda, Céréales) et l'univers "Frais/Santé" (Poisson, Salade, Yaourt) fonctionnent en parallèle sans jamais se croiser. Cette structure en "tuyaux" prouve l'absence de porosité entre les profils : un client qui achète des produits transformés (Soda) n'achète quasiment jamais de produits frais ou bio dans le même panier.

D. Visualisation des règles d'association sous forme de graphe interactif



Analyse

Cette image représente les règles d'association sous forme de réseau.

- **Les Nœuds Verts (Items)** : Ils représentent les produits (ex : *Lait, Pommes*).
- **Les Cercles Rouges (Règles)** : Ils matérialisent les connexions.
 - La **taille** du cercle rouge correspond généralement au **Support** (fréquence).
 - La **couleur** (du rose au rouge foncé) correspond au **Lift** (force du lien). Plus c'est foncé, plus le lien est fort.
- **Les Flèches** : Elles indiquent le sens de l'implication (Produit A -> Règle -> Produit B).
On observe 4 grandes groupes de paniers.

Interprétation

Le graphe de réseau confirme visuellement une segmentation totale des comportements d'achat sous forme de quatre communautés distinctes qui ne sont reliées par aucune passerelle. On identifie clairement :

- Le pôle "Famille" (Lait, Céréales, Purée, Jambon) centré sur le petit-déjeuner et les repas simples.
- Le pôle "Santé/Frais" (Poisson, Salade, Yaourt, Pomme) aux liens très forts.
- Le pôle "Repas Rapide" (Pâtes, Soda, Sauce tomate).
- Le pôle "Bio" qui est totalement isolé.
- Cette structure prouve l'absence de mixité dans les paniers : les clients appartiennent à un profil de consommation précis et "naviguent" rarement d'un univers produit à l'autre lors d'une même visite.

4. Règles d'association indiquant les achats les plus fréquents

A. Règles d'association par genre

Notre matrice de données comporte des instances dont le genre est non renseigné et sont marqués '-'. On les a donc transformés en «NA » afin de pouvoir extraire les règles d'association convenablement.

❖ Cas Genre=Homme

Analyse

L'analyse a été menée dans deux directions : ce que les hommes achètent (*LHS*) et quels produits prédisent qu'un client est un homme (*RHS*).

- **Comportement d'achat des Hommes (LHS) :**
 - Les règles {Genre=Homme} => {Produit} montrent une préférence marquée pour trois articles : **Sauce tomate, Soda, Pâtes**.
 - Ces règles ont un **Support** élevé (entre 22% et 24%), ce qui signifie que près d'un quart des paniers totaux sont des hommes achetant ces produits.
 - Le **Lift** est significatif (~1.50), indiquant que les hommes sont 1,5 fois plus susceptibles d'acheter ces produits que le client moyen.
- **Pouvoir Prédicatif des Produits (RHS) :**

- Les règles inverses sont extrêmement puissantes. Si un panier contient {Soda}, {Pâtes} ou {Sauce_tomate}, la probabilité (**Confiance**) que le client soit un homme est d'environ **80%**.
- **L'effet cumulatif** : La règle n°8 montre que si un client achète le trio {Pâtes=1, Sauce_tomate=1, Soda=1}, il y a **94,2% de chances** (Confiance = 0.942) que ce soit un homme.
- **Produits Neutres** : Pour les produits "Frais" ou "Bio" (Poisson, Légumes_bio, Viande_bio), le **Lift est proche de 1** (0.97 à 1.00) et la confiance tourne autour de 50-53%. Cela signifie que l'achat de bio ou de poisson est neutre par rapport au genre (les hommes en achètent autant que les femmes, ni plus, ni moins).

Interprétation

Le genre masculin capture la quasi-totalité du groupe '**Repas Rapide**'. Avec une fiabilité de **94%**, le panier type *Pâtes/Sauce/Soda* permet d'identifier un client homme. À l'inverse, la consommation de produits Bio ou Frais est mixte et ne dépend pas du genre.

❖ Cas Genre=Femme

Analyse

L'analyse du segment féminin met en évidence des comportements plus nuancés que chez les hommes, avec une répartition des achats sur plusieurs catégories.

- **Comportement d'achat des Femmes (LHS) :**
 - **Le produit phare** : La règle {Genre=Femme} => {Salade} est la plus fréquente (Support : 21,2%). Près de la moitié des femmes identifiées dans la base (47%) achètent de la salade.
 - **La spécificité** : Les règles concernant le **Poulet** et les **Haricots** affichent les **Lifts les plus élevés** (1.52 et 1.51). Cela signifie qu'une femme a 50% plus de chances d'acheter ces produits qu'un client lambda.
 - **L'achat "Ménage"** : On retrouve ensuite tous les produits du "Panier Famille" (Yaourt, Purée, Céréales, Lait) avec des supports moyens (~14%) et des lifts faibles (~1.10), indiquant un achat régulier mais moins caractéristique.
- **Pouvoir Prédictif (RHS) :**
 - **Le marqueur absolu** : La règle combinée {Haricots, Poulet} => {Genre=Femme} est déterminante. Si ce binôme est présent dans le panier, la confiance monte à **84,9%**. C'est le signal le plus fiable pour identifier une cliente.
 - **La neutralité du reste** : Pour la majorité des autres produits (Bio, Lait, Céréales, Poisson), la confiance oscille entre 48% et 53%. Comme ce chiffre est proche de la moyenne aléatoire (50/50), ces produits ne sont pas des indicateurs de genre fiables.

Interprétation

Le segment Femme se caractérise par une consommation prédominante de produits frais (**Salade**) et une signature comportementale forte autour de la préparation de repas (**Poulet/Haricots**). Contrairement aux hommes, très segmentés, les femmes sont actives sur l'ensemble des rayons (Famille, Frais, Bio), jouant un rôle central et transversal dans les achats du foyer.

B. Règles d'association par catégorie d'âge

Pour ce cas, nous avons réalisé une discrétisation avec la fonction quantile () après avoir retiré les valeurs aberrantes (ex : 991) qui ne représentent pas des âges réels.

Nous obtenons ainsi trois catégories d'âge à savoir : « Jeune », « Adulte », et « Vieux ».

❖ **Cas Age=Jeune**

Analyse

Les données isolent un comportement d'achat très spécifique, concentré sur trois produits quasi-exclusifs.

- **Comportement d'achat des Jeunes (LHS) :**
 - **Une trilogie dominante** : Les jeunes se concentrent massivement sur **Sauce tomate, Pâtes et Soda**.
 - **Un Lift très élevé (> 2.0)** : Pour ces trois produits, le Lift est supérieur à 2. Cela signifie qu'un jeune est **deux fois plus susceptible** d'acheter ces articles qu'un client moyen.
 - **Volume** : Avec un support d'environ 20%, ces achats représentent une part très significative du chiffre d'affaires total du magasin.
- **Pouvoir Prédictif (RHS) :**
 - **L'effet de groupe** : Si un produit seul (ex : Pâtes) prédit qu'un client est jeune avec une confiance de ~70%, la combinaison de produits fait exploser cette probabilité.
 - **La quasi-certitude** : Le duo {Pâtes, Soda} offre une **confiance de 88%** (Lift 2.64). Autrement dit, près de 9 paniers sur 10 contenant ce duo appartiennent à des jeunes.

Interprétation

La catégorie 'Jeune' possède une signature d'achat unique et exclusive centrée sur l'ensemble **Pâtes/Sauce_tomate/Soda**. Avec des Lifts supérieurs à 2.6 pour les achats combinés, ce segment est le plus prédictible du magasin.

❖ **Cas Age=Adulte**

Analyse

Les données montrent une rupture nette avec le segment "Jeune". Ici, les produits "plaisir immédiat" (Soda) disparaissent au profit de produits de fond de placard.

- **Comportement d'achat des Adultes (LHS) :**
 - **Les "4 Fantastiques"** : Quatre produits dominent systématiquement le panier des adultes : **Lait, Purée, Jambon, Céréales**.
 - **Fréquence d'achat** : Pour chacun de ces produits, la **Confiance** tourne autour de **50%**. Cela signifie qu'un adulte sur deux qui entre dans le magasin achète du lait ou du jambon.

- **Sur-représentation** : Le **Lift** oscille entre **1.68 et 1.88**. Les adultes sont presque deux fois plus susceptibles d'acheter ces produits que la moyenne des clients.
- **Pouvoir Prédicatif (RHS) :**
 - **L'Indicateur Familial** : Si un panier contient du **Lait** ou du **Jambon**, la probabilité que le client soit un adulte dépasse les **60%** (Confiance de 0.63 pour le lait).
 - **Moins exclusif que les Jeunes** : Bien que le lien soit fort, il est moins "caricatural" que chez les jeunes (qui atteignaient 88% avec le Soda). Cela suggère que si les adultes sont les principaux acheteurs de Lait/Purée, ils ne sont pas les seuls.

Interprétation

La catégorie 'Adulte' incarne le profil du 'Responsable de Famille'. Leur consommation se concentre sur les produits de première nécessité (**Lait, Jambon, Purée, Céréales**) avec une régularité impressionnante (1 adulte sur 2).

❖ Cas Age=Vieux

Analyse

Les données isolent un comportement d'achat très cohérent, focalisé sur les produits frais et non transformés.

- **Comportement d'achat des Seniors (LHS) :**
 - **Le Carré "Santé"** : Quatre produits se détachent nettement : **Yaourt, Salade, Poisson, Pommes**.
 - **Forte Prévalence** : Les règles {Age_cat=Vieux} => {Produit} ont des confiances très élevées (63% à 68%). Cela signifie que près de **2 seniors sur 3** achètent ces produits lors de leur visite.
 - **Exclusivité (Lift)** : Le Lift du **Yaourt (2.34)** et du **Poisson (2.28)** est très fort. Les seniors sont plus de deux fois plus enclins à acheter ces produits que la moyenne.
- **Pouvoir Prédicatif (RHS) :**
 - **Des marqueurs quasi-certains** : Si les produits pris isolément sont déjà de bons indicateurs (73-75% de chance que l'acheteur soit un senior pour le Poisson ou le Yaourt), les combinaisons sont redoutables.
 - **Le record de fiabilité** : La règle {Poisson, Pommes} => {Age_cat=Vieux} atteint une **confiance de 91,6%**.
 - **L'identification** : Dès qu'un panier contient au moins deux produits de la liste (ex : Poisson + Yaourt), il y a environ **9 chances sur 10** que le client appartienne à la catégorie "Vieux".

Interprétation

Le segment 'Vieux' (Seniors) est le pilier des rayons produits frais. Avec une fiabilité de prédiction dépassant les **91%** pour le duo **Poisson/Pommes**, ce groupe se distingue par une consommation 'Santé' exclusive. Ils sont les principaux consommateurs de produits à forte valeur nutritionnelle (Poisson, Yaourt), un univers qu'ils partagent très peu avec les autres générations.

C. Règles d'association par catégorie de revenus des clients

Pour ce cas, nous avons réalisé une discrétisation avec la fonction quantile. Nous obtenons ainsi trois catégories d'âge à savoir : « faible », « médian », et « élevé ».

❖ Cas Revenu=Faible

Analyse

L'analyse distingue deux dynamiques d'achat : la recherche de calories à bas prix et le maintien d'une alimentation basique.

- **Comportement d'achat des Revenus Faibles (LHS) :**
 - **Le Trio Économique :** Les produits **Sauce tomate, Pâtes et Soda** dominent le classement. Près d'un foyer modeste sur deux (48%) achète ces articles.
 - **L'Intensité (Lift) :** Le **Lift** pour les Pâtes est de **1.72**. Cela signifie que les revenus faibles sont 72% plus susceptibles d'acheter des pâtes que la moyenne des clients.
 - **Présence du Frais :** Contrairement au segment "Jeune" qui semblait exclure le frais, les revenus faibles achètent tout de même de la **Salade, du Yaourt et du Poisson** (Confiance entre 36% et 41%). Le Lift reste positif (>1.2), indiquant que ces achats ne sont pas négligés malgré le budget.
- **Pouvoir Prédictif (RHS) :**
 - **Le marqueur de précarité :** La combinaison {Pâtes, Soda} est le plus fort indicateur de ce segment. Avec un **Lift de 2.00**, ce duo double la probabilité que le client appartienne à la catégorie "Revenu Faible".
 - **La confiance cumulée :** Si un client achète {Pâtes + Soda}, il y a **66,7% de chance** (Confiance) qu'il soit à faible revenu.
 - **La nuance du frais :** Bien que les revenus faibles achètent de la salade, ce n'est pas un marqueur fiable pour les identifier (Confiance de 39% seulement), car d'autres segments plus aisés en achètent probablement davantage.

Interprétation

Le segment 'Revenu Faible' se définit par une consommation utilitaire. Le marqueur le plus fiable est l'achat combiné de **Pâtes et de Soda** (Lift 2.0), signature d'une recherche de produits économiques. Cependant, contrairement aux jeunes, ce groupe ne délaisse pas totalement les produits frais (Poisson, Yaourt), suggérant une composition démographique mixte incluant probablement des foyers modestes soucieux de maintenir une alimentation équilibrée.

❖ Cas Revenu=médian

Analyse

- **Comportement d'achat des Revenus Médians (LHS) :**
 - **Un Panier "Standard"** : Les produits les plus fréquents sont la **Salade** (Support 0.133), la **Purée** (0.128) et le **Lait** (0.126).
 - **Lifts Modérés** : Les lifts sont positifs mais jamais explosifs. Le plus fort est sur le **Lait (1.35)** et la **Purée (1.34)**. Cela signifie que les revenus médians achètent ces produits 35% plus souvent que la moyenne, ce qui est significatif mais moins spectaculaire que les lifts >2.0 observés sur les segments "Jeune" ou "Vieux".
 - **Diversité** : Ils achètent un peu de tout : du frais (Salade, Poisson, Yaourt) et de l'épicerie (Purée, Céréales).
- **Pouvoir Prédictif (RHS) :**
 - **Aucun marqueur absolu** : Contrairement au segment "Jeune" où le Soda permettait d'identifier le client à 90%, ici, aucun produit ne dépasse les **45% de confiance**.
 - **Le meilleur indice** : Le **Lait** est le meilleur indicateur (Confiance 0.451). Si quelqu'un achète du lait, il y a 45% de chances qu'il soit de revenu médian. C'est mieux que le hasard (33%), mais cela reste incertain.

Interprétation

Le segment 'Revenu Médian' représente le profil **standard** de la clientèle. Contrairement aux autres groupes très typés, ce segment est éclectique et consomme de tout (Frais et Épicerie) avec une légère préférence pour les basiques familiaux (**Lait, Purée, Lift 1.35**). L'absence de marqueurs forts rend ce groupe difficile à segmenter par le produit seul ; ils constituent le cœur de cible des opérations généralistes sur les produits du quotidien.

❖ Cas Revenu=Elevé

Analyse

L'analyse identifie une consommation de "niche" à forte valeur ajoutée, totalement distincte des autres groupes.

- **Comportement d'achat des Revenus Élevés (LHS) :**
 - **L'Hégémonie du Bio** : Les 4 premières règles concernent exclusivement la gamme Bio : **Légumes_bio, Viande_bio, Fruits_bio, Poisson_bio**.
 - **Un Lift > 2.0** : Avec des lifts autour de **2.10**, les clients aisés sont deux fois plus susceptibles d'acheter du Bio que la moyenne.
 - **Le fond de panier** : On retrouve ensuite les classiques (Purée, Lait, Jambon) avec un Lift modéré (~1.40). Cela indique que même les riches achètent des produits basiques, mais ce n'est pas ce qui les distingue le plus.
- **Pouvoir Prédictif (RHS) :**

- **La Certitude Statistique** : Si l'achat d'un seul produit bio prédit un revenu élevé à ~70%, le cumul est radical.
- **La règle d'or** : Les règles n°9 et n°11 montrent que si un panier contient deux produits bio (ex : {Légumes_bio, Poisson_bio}), il y a **93% de chances** (Confiance > 0.93) que le client ait un revenu élevé.
- **Exclusivité** : C'est le taux de prédiction le plus fort de toute votre étude (avec le duo Pâtes/Soda des jeunes). Le Bio est un marqueur social absolu dans ce magasin.

Interprétation

Le segment 'Revenu Élevé' s'approprie la totalité de l'offre **Bio** du magasin. C'est un cluster fermé et élitiste : la présence de deux articles Bio dans un panier permet d'identifier ce profil avec une certitude de **93%**. Contrairement aux Seniors qui privilégient le produit brut (Frais), ce segment privilégie le produit labellisé, confirmant une consommation statutaire peu sensible au prix

5. Itemsets fréquents indiquant les 4 articles le plus fréquemment achetés dans les 10 % de transactions dont le plus montant est le plus élevé

Analyse

- **Le "Carré Magique" dominant** : Le quadruplet {Poisson, Pommes, Salade, Yaourt} écrase la concurrence avec un **support de 21,9%**. Cela signifie que dans plus d'un gros panier sur cinq, on retrouve systématiquement ces 4 produits frais ensemble. C'est le pilier central des dépenses élevées.
- **Diversité des produits (Mixité)** : Contrairement aux analyses précédentes qui montraient des silos (Bio vs Junk Food), les gros paniers montrent une **hybridation**. On y trouve mélangés :
 - Du **Frais** (Poisson, Salade).
 - Du **Bio** (Fruits_bio, Viande_bio, Poisson_bio).
 - De l'**Épicerie** (Café, Pâtes, Purée, Céréales).
 - Du **Frais** (Jambon, Lait).
- **L'apparition du "Café"** : C'est un nouvel item qui apparaît fréquemment dans ces combinaisons (ex : règles 3, 5, 6, 7...), alors qu'il était discret dans les segments précédents. Le Café est souvent un produit de marque, plus cher, typique des achats de "plein" (grosses courses)

Interprétation

L'analyse des transactions à plus forte valeur monétaire (le top 10%) met en lumière une dynamique d'achat bien plus complexe que la simple segmentation par rayon observée précédemment.

Contrairement aux autres profils qui restent cantonnés à un univers spécifique, ces "gros paniers" se caractérisent par une **transversalité totale**. On y observe en effet la cohabitation systématique d'un socle de produits frais (le quadruplet Poisson/Salade/Yaourt/Pommes étant présent dans plus de 20% des cas) avec des articles à forte valeur faciale comme la viande Bio ou le café, ainsi que des produits de stockage basiques. Cette structure hybride révèle le comportement type d'un **ménage réalisant ses courses hebdomadaires complètes** : il concilie le volume nécessaire au fonctionnement du foyer avec une exigence qualitative élevée, ce qui explique mécaniquement le montant important du ticket de caisse.

6. Clusters regroupant les clients ayant des caractéristiques et des comportements d'achats similaires


Pour réaliser la segmentation de la clientèle, nous avons utilisé l'algorithme de partitionnement des **K-Means (K-Moyennes)**. Cette méthode a été choisie pour sa capacité à regrouper efficacement les clients en classes homogènes autour de profils types (centroïdes)

Avant d'analyser les profils, nous avons confronté trois méthodes statistiques pour déterminer le découpage optimal de la clientèle.

- **Méthode du Coude (Elbow Method)** : La courbe « *Within Sum of Square* » montre une décroissance rapide jusqu'à **k=4** suggérant qu'une segmentation en 4 grands groupes suffit pour expliquer la variance principale.
 - **Silhouette & Gap Statistic** : Ces deux méthodes, plus fines pour détecter la cohérence interne des groupes, indiquent un optimum mathématique à **k=6**. Le score de silhouette moyen est maximisé à ce niveau, prouvant que les groupes sont mieux détournés et plus homogènes.
- Nous avons choisi de retenir k=6 clusters. Bien que le modèle à 4 clusters soit plus simple, passer à 6 permet de révéler des segments de niche stratégiques (comme les "Gros acheteurs" ou les "Cuisiniers traditionnels") qui restaient cachés dans une segmentation trop généraliste.

7. Caractérisation des clusters extraits (Profilage Socio-Demographique)

Heatmap : Intensité des achats par Cluster



Visualisation des clusters extraits

	Cluster	Moyenne_Enfants	Moyenne_Montant	Classe_Age_Dominante	Classe_Revenu_Dominante	Mode_Genre	Mode_Statut	Effectif
1	1	2.4633	29.7	Adulte	median	Femme	Marié(e)	436
2	2	0.5364	33.1	Vieux	faible	Femme	Veuf(ve)	412
3	3	1.5723	67.8	Vieux	élevé	Femme	Célibataire	159
4	4	0.0655	24.7	Jeune	faible	Homme	Célibataire	458
5	5	0.3162	26.2	Jeune	median	Femme	Célibataire	291
6	6	1.0041	30.2	Adulte	élevé	Homme	Marié(e)	244

Synthèse Clusters

Analyse du Tableau Socio-Démographique

Ce tableau nous donne le profil "civil" de chaque cluster. Voici ce qu'il faut retenir ligne par ligne :

- Cluster 1 (La Famille Classique) : Ce groupe se distingue par le nombre d'enfants le plus élevé (2.46). Ce sont des adultes (35-55 ans), majoritairement mariés, avec un revenu médian. Leur panier moyen est standard (~30€).
- Cluster 2 (Les Retraités Modestes) : Ce sont des clients âgés ("Vieux"), majoritairement des femmes veuves (Mode_Statut = Veuf(ve)) avec un revenu faible. Notez que malgré le revenu faible, leur panier (33.1€) est plus élevé que celui des jeunes, prouvant une consommation alimentaire prioritaire.

- **Cluster 3 (L'Élite Senior)** : C'est le cluster "Star". Ils sont âgés ("Vieux") mais disposent d'un **revenu élevé**. Conséquence directe : ils ont le **panier moyen le plus élevé du magasin (67.8€)**, soit le double des autres !
- **Cluster 4 (Les Jeunes Précaires)** : Profil très typé : **Jeune, Homme, Célibataire, Revenu Faible**. C'est le groupe avec le panier moyen le plus bas (24.7€), signe d'une contrainte budgétaire forte.
- **Cluster 5 (Les Jeunes Actives)** : Ce sont également des jeunes célibataires, mais majoritairement des **Femmes** avec un revenu **médian**. Elles dépensent peu (26.2€), probablement pour des repas individuels.
- **Cluster 6 (Les Pères de Famille Aisés)** : Ce sont des Adultes, **Hommes**, Mariés, avec un **revenu élevé**. Ils ont environ 1 enfant (1.00) et un panier moyen correct (30.2€)

Analyse de la Heatmap

Voici l'interprétation des profils types pour chaque groupe :

Cluster 6 : Les "Bio-Addicts"

- **Produits phares** : *Fruits_bio, Legumes_bio, Poisson_bio, Viande_bio*.
- **Interprétation** : Ce groupe est très clairement défini par sa préférence pour les produits étiquetés "Bio". Ils ignorent presque totalement les produits transformés ou standards.
- **Profil client probable** : Clients soucieux de leur santé et de l'environnement, probablement avec un pouvoir d'achat plus élevé (le bio étant souvent plus cher).

Cluster 5 : Les "Mangeurs Équilibrés / Diététiques"

- **Produits phares** : *Haricots, Poulet, Salade*.
- **Interprétation** : Ce panier est composé de protéines maigres (poulet) et de légumes verts/fibres (haricots, salade). On remarque l'absence de féculents lourds ou de produits sucrés.
- **Profil client probable** : Personnes faisant attention à leur ligne, sportifs, ou personnes suivant un régime spécifique low-carb.

Cluster 4 : Les "Pasta Lovers" (Repas Rapides)

- **Produits phares** : *Pâtes, Sauce_tomate*.
- **Interprétation** : C'est le stéréotype du repas simple et économique. L'achat est très ciblé sur ces deux ingrédients complémentaires.
- **Profil client probable** : Étudiants, jeunes actifs, ou personnes cherchant des repas très économiques et rapides à préparer sans grande compétence culinaire.

Cluster 3 : Les "Gros Consommateurs / Généralistes" (Dominante Café)

- **Produits phares** : *Café* (très intense), mais on note une couleur rosée pâle/blanche diffuse sur presque toute la ligne.
- **Interprétation** : Contrairement aux autres clusters qui sont très spécialisés (taches roses sur fond bleu), ce cluster semble acheter un peu de tout (le fond n'est pas bleu pur), avec une consommation massive de café.
- **Profil client probable** : Familles nombreuses faisant le "gros plein" ou peut-être des achats pour des bureaux/entreprises (gros volume de café + variété d'autres produits pour la collectivité).

Cluster 2 : Les "Fraîcheur Standard"

- **Produits phares** : *Poisson, Pommes, Salade, Yaourt, Viande_bio.*
- **Interprétation** : Ce groupe achète des produits frais et sains, mais contrairement au Cluster 6, ils ne sont pas exclusivement focalisés sur le "Bio" (ils achètent du poisson standard, des pommes standard), bien qu'ils prennent parfois de la viande bio. Ils consomment aussi des laitages (Yaourt).
- **Profil client probable** : Foyers cuisinant des produits frais, profil traditionnel équilibré.

Cluster 1 : Les "Familiaux / Comfort Food"

- **Produits phares** : *Céréales, Jambon, Lait, Purée.*
- **Interprétation** : Ce panier associe le petit-déjeuner classique (Céréales + Lait) et des repas très "confort" et faciles pour les enfants (Jambon + Purée).
- **Profil client probable** : Familles avec enfants en bas âge ou d'âge scolaire. Ce sont des repas qui plaisent aux enfants et sont rapides à mettre en œuvre le soir.

CONCLUSION

Ce projet d'analyse de données nous a permis d'explorer en profondeur les comportements d'achat d'une clientèle de grande distribution en croisant des données transactionnelles (tickets de caisse) et socio-démographiques. L'application combinée des règles d'association (algorithme Apriori) et du partitionnement (algorithme K-Means) a révélé une segmentation de clientèle particulièrement nette et actionnable.

Synthèse des résultats :

L'analyse révèle **6 profils clients distincts**, polarisés par le pouvoir d'achat et la structure familiale. On distingue clairement :

- Les profils "**Économiques**" : Étudiants (panier "survie") et Familles nombreuses (panier "volume").
- Les profils "**Qualitatifs**" : Seniors aisés, Bio-Addicts et Mangeurs équilibrés. Les règles d'association confirment ces comportements avec une forte fiabilité

Difficultés et limites Nous avons dû surmonter deux défis majeurs :

1. **La qualité des données** : Le traitement nécessaire des valeurs aberrantes (âges > 900 ans) et des données manquantes pour ne pas biaiser l'analyse.
2. **Le choix du nombre de clusters** : Nous avons arbitré en faveur de **6 groupes** (validé par le coefficient de Silhouette) plutôt que 3 (méthode du kmeans afin de ne pas masquer des segments stratégiques).

Cette segmentation offre désormais une base solide pour mettre en place des actions marketing ciblées.